



INSTITUTO POLITÉCNICO NACIONAL
ESCUELA SUPERIOR DE CÓMPUTO

Unidad de Aprendizaje: Probabilidad y Estadística

**Reporte Técnico: Simulador
Computacional de Distribuciones de
Probabilidad y Visualizaciones Gráficas**

Proyecto del Segundo Parcial

Integrantes del Equipo:

- Diego Ruperto Hernández (Boleta: 2024630696)

Grupo: 4CM3

Profesor: David Correa Coyac

Fecha de Entrega: 27 de Mayo de 2026

Índice

1. Introducción	2
2. Objetivo	2
3. Fundamento Teórico	3
3.1. Variables Aleatorias Discretas y Continuas	3
3.2. Momentos Estadísticos: Esperanza, Varianza y Desviación Estándar . .	4
3.3. Modelos de Distribución Implementados	4
3.3.1. Modelos Discretos	4
3.3.2. Modelos Continuos	5
3.4. Teoremas Fundamentales de Convergencia	6
4. Descripción del Programa y Justificación del Entorno	7
4.1. Arquitectura Modular del Proyecto	7
4.2. Justificación de las Librerías Utilizadas	7
4.3. Contenedor e Infraestructura con Docker	8
5. Resultados y Casos de Prueba	9
5.1. Experimento 1: Distribución Binomial	9
5.2. Experimento 2: Distribución Poisson	10
5.3. Experimento 3: Distribución Geométrica	11
5.4. Experimento 4: Distribución Normal	12
5.5. Experimento 5: Distribución Uniforme Continua	13
5.6. Experimento 6: Distribución Exponencial	14
6. Análisis e Interpretación Estadística	15
7. Conclusión	16
8. Referencias	17
8.1. Documentación Oficial de Librerías y Frameworks	17
8.2. Recursos Audiovisuales y Videografía (YouTube)	17
9. Anexo: Repositorio e Instrucciones Adicionales	18

1. Introducción

La simulación de distribuciones de probabilidad mediante métodos computacionales constituye una de las herramientas más potentes y versátiles en la ciencia de datos y la ingeniería moderna. En lugar de depender exclusivamente de aproximaciones analíticas puras, el desarrollo de software nos permite recrear experimentos estocásticos bajo condiciones controladas, generando miles o millones de observaciones pseudoaleatorias en fracciones de segundo.

Este enfoque no solo complementa la teoría matemática abstracta revisada en el aula, sino que provee una validación empírica palpable de leyes fundamentales de la estadística. Al modelar numéricamente el comportamiento de variables aleatorias, tanto discretas como continuas, los ingenieros en sistemas computacionales pueden predecir fallos en arquitecturas de red, optimizar tiempos de espera en servidores mediante modelos de colas, o simular escenarios económicos complejos. El presente reporte detalla el diseño, la fundamentación teórica y la implementación contenedorizada de un simulador estadístico avanzado enfocado en la interactividad y rigor matemático.

2. Objetivo

Desarrollar e implementar una aplicación web interactiva y modular que funcione como un simulador computacional de distribuciones de probabilidad. El sistema debe permitir la configuración dinámica de parámetros para seis modelos probabilísticos esenciales (tres discretos y tres continuos), generar muestras de datos de tamaño de muestra arbitrario, graficar el comportamiento empírico contra las curvas de densidad teóricas, y contrastar de manera tabular los estadísticos de media, varianza y desviación estándar simulados contra sus valores analíticos esperados.

3. Fundamento Teórico

El núcleo conceptual de este simulador computacional descansa sobre la teoría clásica de la probabilidad y la inferencia estadística. A continuación, se delimitan rigurosamente los conceptos de variables aleatorias, funciones de distribución y las formulaciones analíticas de los modelos implementados.

3.1. Variables Aleatorias Discretas y Continuas

Una variable aleatoria X es formalmente una función medible definida desde un espacio muestral Ω hacia el conjunto de los números reales $\mathbb{R}$ ($X : \Omega \rightarrow \mathbb{R}$). La clasificación de estas variables determina de forma unívoca el tratamiento matemático y numérico que el simulador debe ejecutar:

- **Variables Aleatorias Discretas:** Son aquellas cuyo soporte (el conjunto de valores posibles que pueden asumir) es finito o infinito numerable. La asignación de probabilidades a cada punto de su soporte se realiza mediante la Función de Masa de Probabilidad (PMF, por sus siglas en inglés), denotada como $p(x) = P(X = x)$, la cual cumple estrictamente de acuerdo con los axiomas de Kolmogorov:

$$p(x) \geq 0, \quad \forall x \in \text{Soporte}(X) \quad \text{y} \quad \sum_x p(x) = 1 \quad (1)$$

- **Variables Aleatorias Continuas:** Son aquellas cuyo soporte está constituido por un conjunto infinito no numerable de valores, típicamente intervalos dentro de $\mathbb{R}$. A diferencia de las discretas, la probabilidad de que una variable continua tome un valor exacto aislado es matemáticamente nula ($P(X = x) = 0$). Por ende, la asignación de probabilidades sobre un intervalo se define mediante la integral de la Función de Densidad de Probabilidad (PDF), denotada como $f(x)$, la cual satisface:

$$f(x) \geq 0, \quad \forall x \in \mathbb{R} \quad \text{y} \quad \int_{-\infty}^{\infty} f(x) dx = 1 \quad (2)$$

De este modo, la probabilidad de transición entre dos límites a y b se calcula como:

$$P(a \leq X \leq b) = \int_a^b f(x) dx \quad (3)$$

3.2. Momentos Estadísticos: Esperanza, Varianza y Desviación Estándar

Para caracterizar analíticamente cualquier distribución, el software calcula sus momentos estadísticos fundamentales, comparando los operadores teóricos abstractos contra los estimadores empíricos muestrales.

La **Esperanza Matemática** o Media (μ) representa el centro de gravedad de la distribución. Matemáticamente se define como:

$$\mu = E[X] = \begin{cases} \sum_x x \cdot p(x) & \text{(Caso Discreto)} \\ \int_{-\infty}^{\infty} x \cdot f(x) dx & \text{(Caso Continuo)} \end{cases} \quad (4)$$

La **Varianza** (σ^2) cuantifica la dispersión cuadrática media de los datos en torno a su esperanza matemática, denotada formalmente como el segundo momento central:

$$\sigma^2 = Var(X) = E[(X - \mu)^2] = E[X^2] - (E[X])^2 \quad (5)$$

Específicamente se desglosa operacionalmente mediante:

$$Var(X) = \begin{cases} \sum_x (x - \mu)^2 \cdot p(x) & \text{(Caso Discreto)} \\ \int_{-\infty}^{\infty} (x - \mu)^2 \cdot f(x) dx & \text{(Caso Continuo)} \end{cases} \quad (6)$$

Dado que la varianza se expresa en unidades al cuadrado, el simulador extrae la raíz cuadrada estricta para obtener la **Desviación Estándar** (σ), devolviendo la dispersión a la escala original de la variable de estudio:

$$\sigma = \sqrt{Var(X)} \quad (7)$$

3.3. Modelos de Distribución Implementados

3.3.1. Modelos Discretos

1. **Distribución de Bernoulli:** Modela un único experimento aleatorio con dos resultados posibles: “éxito” (con probabilidad p) o “fracaso” (con probabilidad $1 - p$).

- *PMF:* $p(x) = p^x(1 - p)^{1-x}$, $x \in \{0, 1\}$
- *Media Teórica:* $\mu = p$
- *Varianza Teórica:* $\sigma^2 = p(1 - p)$

2. **Distribución Binomial:** Expresa el número de éxitos al realizar n ensayos de Bernoulli independientes entre sí.

- *PMF:* $p(x) = \binom{n}{x} p^x (1 - p)^{n-x}$, $x \in \{0, 1, \dots, n\}$
- *Media Teórica:* $\mu = np$
- *Varianza Teórica:* $\sigma^2 = np(1 - p)$

3. **Distribución Geométrica:** Cuenta el número de fracasos acumulados antes de que ocurra el primer éxito en una secuencia de ensayos de Bernoulli.

- *PMF:* $p(x) = (1-p)^x p, \quad x \in \{0, 1, 2, \dots\}$
- *Media Teórica:* $\mu = \frac{1-p}{p}$
- *Varianza Teórica:* $\sigma^2 = \frac{1-p}{p^2}$

4. **Distribución de Poisson:** Expresa la probabilidad de que ocurra un número determinado de eventos independientes en un intervalo fijo de tiempo o espacio, bajo una tasa media de ocurrencia constante λ .

- *PMF:* $p(x) = \frac{\lambda^x e^{-\lambda}}{x!}, \quad x \in \{0, 1, 2, \dots\}$
- *Media Teórica:* $\mu = \lambda$
- *Varianza Teórica:* $\sigma^2 = \lambda$

3.3.2. Modelos Continuos

1. **Distribución Uniforme Continua:** Distribuye la probabilidad de manera estrictamente equitativa a lo largo de un intervalo acotado por un límite inferior a y un límite superior b .

- *PDF:* $f(x) = \frac{1}{b-a}, \quad \forall x \in [a, b]$
- *Media Teórica:* $\mu = \frac{a+b}{2}$
- *Varianza Teórica:* $\sigma^2 = \frac{(b-a)^2}{12}$

2. **Distribución Normal (Gaussiana):** Es el modelo continuo más trascendental. Queda completamente caracterizado por su media ubicación μ y su desviación estándar σ . Su perfil gráfico genera la icónica campana simétrica de Gauss.

- *PDF:* $f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right), \quad x \in \mathbb{R}$
- *Media Teórica:* $E[X] = \mu$
- *Varianza Teórica:* $\text{Var}(X) = \sigma^2$

3. **Distribución Exponencial:** Modela el tiempo transcurrido entre la ocurrencia de dos eventos consecutivos de Poisson, caracterizada por un parámetro de escala continuo β (donde $\beta = 1/\lambda$).

- *PDF:* $f(x) = \frac{1}{\beta} e^{-\frac{x}{\beta}}, \quad x \geq 0$
- *Media Teórica:* $\mu = \beta$
- *Varianza Teórica:* $\sigma^2 = \beta^2$

3.4. Teoremas Fundamentales de Convergencia

El soporte algorítmico de los módulos interactivos avanzados del simulador se fundamenta en dos pilares de la teoría asintótica:

- **Ley de los Grandes Números (LGN):** Establece que si $X_1, X_2, \dots, X_n$ es una sucesión infinita de variables aleatorias independientes e idénticamente distribuidas (i.i.d.) con una esperanza matemática finita $E[X] = \mu$, entonces el promedio muestral converge directamente hacia dicho valor teórico conforme el número de observaciones tiende a infinito:

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{n \rightarrow \infty} \mu \quad (8)$$

Este teorema justifica computacionalmente por qué los errores residuales entre los datos empíricos simulados y los parámetros teóricos se desvanecen exponencialmente al configurar tamaños de muestra robustos ($N \geq 10,000$).

- **Teorema del Límite Central (TLC):** Dictamina que la suma o el promedio ponderado de un número suficientemente grande ($n \rightarrow \infty$) de variables aleatorias independientes e idénticamente distribuidas (con media μ y varianza $\sigma^2 > 0$ finitas) tenderá asintóticamente a aproximarse a una distribución normal estándar $N(0, 1)$, de forma independiente a la naturaleza de la distribución original del fenómeno de origen:

$$Z = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} N(0, 1) \quad (9)$$

El simulador explota este principio al colapsar promedios de distribuciones marcadamente asimétricas (como la Geométrica o la Exponencial), desplegando visualmente cómo el histograma resultante adopta la simetría gaussiana a medida que se incrementa el número de muestras agregadas.

4. Descripción del Programa y Justificación del Entorno

El simulador computacional ha sido desarrollado bajo un paradigma arquitectónico modular utilizando el lenguaje de programación **Python**. La estructura del proyecto ha sido segregada minuciosamente para independizar la interfaz gráfica de usuario de la maquinaria lógica y computacional de cálculo, garantizando mantenibilidad, claridad en el flujo de datos y escalabilidad para la adición de futuros módulos estadísticos.

4.1. Arquitectura Modular del Proyecto

El software organiza sus componentes mediante paquetes internos bien delimitados:

- `app.py`: Constituye el punto de entrada de la aplicación y gestiona exclusivamente la capa de visualización (Front-End) basada en la web, procesando las solicitudes interactivas del usuario y organizando el diseño estético mediante pestañas.
- `logica/distribuciones.py`: Encapsula la lógica de validación matemática de parámetros y efectúa el cálculo directo de momentos estadísticos analíticos y estimadores empíricos.
- `logica/simulaciones.py`: Administra la simulación iterativa de vectores aleatorios complejos de alta densidad requeridos por los experimentos asintóticos de la Ley de los Grandes Números y el Teorema del Límite Central.

4.2. Justificación de las Librerías Utilizadas

Para consolidar una herramienta de alto desempeño científico, se seleccionaron librerías especializadas del ecosistema científico de Python, justificadas detalladamente bajo criterios de eficiencia analítica y computacional:

1. **Streamlit**: Este framework interactivo fue seleccionado para materializar el simulador como una aplicación web nativa sin incurrir en la sobrecarga técnica y arquitectónica de diseñar arquitecturas cliente-servidor tradicionales (HTML, CSS, JavaScript acoplados pesadamente). Streamlit permite un enlazado reactivo bidireccional automático entre las entradas de parámetros numéricos del usuario y el renderizado instantáneo de gráficos científicos, agilizando la interacción en tiempo real. <https://docs.streamlit.io>
2. **NumPy (Numerical Python)**: La generación masiva de datos requiere una eficiencia computacional crítica. NumPy gestiona arreglos homogéneos indexados optimizados internamente en lenguaje C (`ndarrays`). Los generadores pseudoaleatorios de su submódulo `numpy.random` implementan algoritmos avanzados de alto espectro (como el generador Mersenne Twister o PCG64), permitiendo instanciar vectores de hasta un millón de muestras flotantes de forma casi instantánea y con un consumo de memoria RAM optimizado. <https://numpy.org/doc/>

3. **SciPy (`scipy.stats`):** Mientras NumPy genera los datos empíricos crudos mediante simulación estocástica, el paquete `scipy.stats` proporciona el marco de validación formal. Esta librería evalúa analíticamente las funciones de masa (PMF) y densidad (PDF) exactas sobre rangos continuos y discretos. De este modo, permite superponer curvas teóricas continuas perfectas por encima de los histogramas muestrales, actuando como el estándar de control de la aplicación. <https://docs.scipy.org/doc/scipy/>
4. **Matplotlib y Seaborn:** La visualización constituye el puente analítico del estudiante. Se integró `matplotlib.pyplot` como motor base para la estructuración de lienzos, manipulación de ejes y etiquetado técnico. Por su parte, `seaborn` extiende estas capacidades proporcionando una capa estética sofisticada de alto nivel. Seaborn se utiliza específicamente para graficar histogramas normalizados combinados de forma automática con estimaciones de densidad por kernel (KDE, Kernel Density Estimation), suavizando la visualización de datos continuos y facilitando la comparación simulación vs. teoría. <https://matplotlib.org/stable/contents.html>

4.3. Contenedor e Infraestructura con Docker

Para mitigar la variabilidad en los entornos de ejecución locales y erradicar conflictos entre versiones de librerías del sistema, la aplicación completa ha sido empaquetada dentro de un contenedor **Docker**.

A través de un archivo de configuración estructurado por capas (**Dockerfile**), se aísla un entorno de ejecución limpio basado en una distribución ligera de GNU/Linux. El contenedor instala las dependencias de Python listadas de forma estricta y expone el puerto de red 8501 de forma nativa. Esto permite mapear el entorno completo desde la línea de comandos hacia el sistema operativo local hospedero de forma limpia y transparente, abstrayendo por completo el software de las configuraciones internas de la máquina física del desarrollador o del evaluador.

5. Resultados y Casos de Prueba

A continuación, se presentan las evidencias gráficas recopiladas directamente de la interfaz del simulador interactivo, junto con el análisis comparativo de los datos empíricos obtenidos frente a los modelos matemáticos analíticos de control.

5.1. Experimento 1: Distribución Binomial

Para validar el comportamiento de este modelo discreto, se configuró el sistema con un número de ensayos de Bernoulli de $n = 50$, una probabilidad de éxito individual de $p = 0,30$ y un tamaño muestral de $N = 10,000$ observaciones.

Tabla 1: Métricas comparativas para la Distribución Binomial ($n = 50, p = 0,30$)

Métrica Estadística	Valor Teórico	Valor Simulado	Diferencia Absoluta
Media (μ)	15.0000	14.9579	0.0421
Varianza (σ^2)	10.5000	10.4134	0.0866
Desviación Estándar (σ)	3.2403	3.2270	0.0134
Tamaño de Muestra (N)	10,000	10,000	0.0000




Figura 1: Interfaz del simulador mostrando el histograma de frecuencias relativas y la curva de masa teórica (PMF) para el caso Binomial.

5.2. Experimento 2: Distribución Poisson

El comportamiento de eventos independientes en un soporte continuo se evaluó configurando una tasa media de ocurrencia de $\lambda = 4,5$ sobre un volumen masivo de $N = 15,000$ iteraciones estocásticas.

Tabla 2: Métricas comparativas para la Distribución Poisson ($\lambda = 4,5$)

Métrica Estadística	Valor Teórico	Valor Simulado	Diferencia Absoluta
Media (μ)	4.5000	4.4573	0.0427
Varianza (σ^2)	4.5000	4.3882	0.1118
Desviación Estándar (σ)	2.1213	2.0948	0.0265
Tamaño de Muestra (N)	15,000	15,000	0.0000




Figura 2: Visualización gráfica de la distribución de Poisson. Se observa la coincidencia asintótica entre la media empírica y el parámetro central.

5.3. Experimento 3: Distribución Geométrica

Se analizó el número de fracasos previos al primer éxito bajo un parámetro de probabilidad de éxito de $p = 0,25$, evaluando una densidad muestral de $N = 12,000$ ejecuciones autónomas.

Tabla 3: Métricas comparativas para la Distribución Geométrica ($p = 0,25$)

Métrica Estadística	Valor Teórico	Valor Simulado	Diferencia Absoluta
Media (μ)	4.0000	4.0319	0.0319
Varianza (σ^2)	12.0000	12.1292	0.1292
Desviación Estándar (σ)	3.4641	3.4827	0.0186
Tamaño de Muestra (N)	12,000	12,000	0.0000




Figura 3: Gráfica de bastones de la distribución geométrica que ilustra el decaimiento monótono discreto característico de este modelo de ensayos.

5.4. Experimento 4: Distribución Normal

Se instanció un escenario gaussiano continuo utilizando parámetros estándar de localización y dispersión: una media aritmética $\mu = 100,0$ y una desviación estándar $\sigma = 15,0$, bajo un tamaño de muestra de $N = 20,000$.

Tabla 4: Métricas comparativas para la Distribución Normal ($\mu = 100,0, \sigma = 15,0$)

Métrica Estadística	Valor Teórico	Valor Simulado	Diferencia Absoluta
Media (μ)	100.0000	100.0356	0.0356
Varianza (σ^2)	225.0000	225.7472	0.7472
Desviación Estándar (σ)	15.0000	15.0249	0.0249
Tamaño de Muestra (N)	20,000	20,000	0.0000




Figura 4: Representación continua del modelo normal; se aprecia la simetría perfecta de la campana gaussiana analítica sobre el histograma empírico.

5.5. Experimento 5: Distribución Uniforme Continua

Se delimitó un dominio de equiprobabilidad continua parametrizando un límite inferior en $a = 10,0$ y un límite superior en $b = 50,0$, recolectando una densidad muestral de $N = 10,000$ observaciones.

Tabla 5: Métricas comparativas para la Distribución Uniforme Continua ($a = 10,0, b = 50,0$)

Métrica Estadística	Valor Teórico	Valor Simulado	Diferencia Absoluta
Media (μ)	30.0000	29.7710	0.2290
Varianza (σ^2)	133.3333	133.4997	0.1663
Desviación Estándar (σ)	11.5470	11.5542	0.0072
Tamaño de Muestra (N)	10,000	10,000	0.0000




Figura 5: Densidad de la distribución uniforme continua, demostrando el comportamiento plano y equitativo de las frecuencias en el intervalo cerrado $[a, b]$.

5.6. Experimento 6: Distribución Exponencial

Por último, se analizó el modelo de decaimiento continuo parametrizando un factor de escala de tiempo o espacio $\beta = 2,5$, recopilando una población finita de $N = 12,000$ datos aleatorios vectorizados.

Tabla 6: Métricas comparativas para la Distribución Exponencial ($\beta = 2,5$)

Métrica Estadística	Valor Teórico	Valor Simulado	Diferencia Absoluta
Media (μ)	2.5000	2.5139	0.0139
Varianza (σ^2)	6.2500	6.4035	0.1535
Desviación Estándar (σ)	2.5000	2.5305	0.0305
Tamaño de Muestra (N)	12,000	12,000	0.0000




Figura 6: Histograma de la simulación exponencial donde se verifica la asimetría positiva extrema y el ajuste perfecto de la curva teórica de densidad.

6. Análisis e Interpretación Estadística

Para dar respuesta puntual a las directrices analíticas marcadas por el comité académico, se desarrollan las siguientes conclusiones interpretativas fundamentadas en el comportamiento matemático observado:

1. **Aproximación de valores simulados frente a teóricos:** En todos los experimentos de ejecución limpia, la media, varianza y desviación estándar de carácter empírico se aproximan de forma sobresaliente a las métricas matemáticas ideales. Esto indica que los algoritmos de muestreo de NumPy modelan adecuadamente las funciones de distribución de probabilidad subyacentes.
2. **Efecto del incremento del tamaño de la muestra (N):** Al modificar la interfaz para transicionar de muestras pequeñas ($N = 50$) a muestras masivas ($N = 100,000$), se observa que el término de la “Diferencia” numérica en las tablas experimentales decrece drásticamente aproximándose a cero. Este fenómeno constituye una demostración empírica de la **Ley de los Grandes Números**, la cual dicta que el promedio aritmético de una muestra aleatoria converge casi seguramente a su valor esperado teórico a medida que el tamaño muestral tiende a infinito.
3. **Diferencia gráfica entre distribuciones discretas y continuas:** El simulador visualiza las distribuciones discretas a través de diagramas de barras espaciados, donde la probabilidad se concentra exclusivamente en puntos aislados del espectro entero, reflejando la Función de Masa (PMF). Por otro lado, las continuas se despliegan mediante histogramas densos normalizados cubiertos por curvas matemáticas continuas y suavizadas (PDF), donde la probabilidad está asociada a áreas sobre intervalos reales.
4. **Origen de las diferencias entre la teoría y la simulación:** Los valores nunca serán exactamente idénticos debido a las fluctuaciones estocásticas naturales inherentes a cualquier proceso aleatorio finito. Además, las computadoras operan con generadores de números *pseudoaleatorios* (algoritmos deterministas basados en condiciones de inicio llamadas “semillas”), los cuales, sumados a las pequeñas limitaciones de redondeo de punto flotante de la arquitectura del hardware de 64 bits, provocan desviaciones marginales.
5. **Limitaciones del simulador computacional:** El simulador presenta restricciones físicas ligadas a la memoria RAM asignada al contenedor de Docker cuando se intentan generar tamaños de muestra masivos extremos (ej. $N \geq 1 \times 10^9$). Asimismo, la precisión matemática se degrada en los extremos de las colas de las distribuciones (como en el cálculo del factorial para valores muy elevados de x en Poisson), lo cual puede inducir a desbordamientos aritméticos (*overflow*).

7. Conclusión

El desarrollo de este simulador demostró que la probabilidad y la estadística son mucho más que fórmulas en un pizarrón; son reglas que describen cómo se comporta el mundo real. Al programar cada uno de los modelos, quedó mucho más clara la diferencia entre contar eventos concretos (como en las distribuciones discretas: Binomial, Poisson) y medir rangos continuos (como en la Normal o Uniforme).

Poner a prueba los teoremas mediante código fue una de las partes más reveladoras del proyecto. Por un lado, la Ley de los Grandes Números nos enseñó que, aunque el azar parece caótico en los primeros intentos, siempre termina estabilizándose hacia un valor predecible si recolectamos suficientes datos. Por otro lado, el Teorema del Límite Central nos permitió comprobar de manera muy visual algo increíble: no importa qué tan extraña o dispareja sea la forma de los datos originales, si tomamos suficientes promedios, estos siempre se agruparán formando la clásica y perfecta campana de Gauss.

Todo esto resalta la enorme importancia de tener resultados visuales y gráficos. Leer números o porcentajes de error en una tabla es útil, pero ver cómo la curva de los datos simulados encaja exactamente sobre la línea teórica hace que conceptos matemáticos muy abstractos se vuelvan fáciles de entender al instante. Las gráficas nos ayudan a confiar en los datos.

Finalmente, la experiencia de trabajar con contenedores fue un gran paso para el proyecto. Usar Docker eliminó por completo el clásico y molesto problema de en mi computadora sí funciona. Al meter todo el programa, junto con las versiones exactas de las librerías, dentro de un contenedor aislado, nos aseguramos de que el simulador sea portátil. Cualquier persona puede descargar el código y correrlo en Windows, Mac o Linux en cuestión de segundos, sin tener que pelear con instalaciones complicadas.

8. Referencias

8.1. Documentación Oficial de Librerías y Frameworks

Streamlit Documentation: Streamlit Inc. (2026). *Streamlit API Reference Guide for Web Application Development*. Recuperado de: <https://docs.streamlit.io>

NumPy Documentation: NumPy Developers. (2025). *NumPy v2.2 Manual and Array Objects Optimization*. Recuperado de: <https://numpy.org/doc/>

SciPy Library: SciPy Community. (2025). *Statistical Functions (scipy.stats) Reference Guide*. Recuperado de: <https://docs.scipy.org/doc/scipy/>

Seaborn Visualization: Waskom, M. (2024). *Statistical Data Visualization with Seaborn and Matplotlib*. Recuperado de: <https://seaborn.pydata.org>

Docker Documentation: Docker Inc. (2026). *Docker Containers and Isolated Virtual Environments for Applications*. Recuperado de: <https://docs.docker.com>

8.2. Recursos Audiovisuales y Videografía (YouTube)

Dot CSV. (2019). *¿Qué es el Teorema del Límite Central? La clave de la estadística* [Video de YouTube]. Disponible en: <https://www.youtube.com/watch?v=4M88fepKkKg>

Anotación: Recurso fundamental utilizado para la comprensión intuitiva de la convergencia asintótica y el diseño algorítmico del módulo del Teorema del Límite Central en el simulador.

StatQuest con Josh Starmer. (2020). *Probability Distributions: Discrete vs Continuous and Probability Density Functions (PDFs)* [Video de YouTube]. Disponible en: https://www.youtube.com/watch?v=b9a27aN_6Zc

Anotación: Video empleado para fundamentar el modelado matemático y diferenciar de forma gráfica y computacional la asignación de probabilidades discretas frente a las integrales de densidad continuas.

Corey Schafer. (2021). *Python Streamlit Tutorial: Deploying Data Science and Simulation Web Apps Instantly* [Video de YouTube]. Disponible en: https://www.youtube.com/watch?v=uKceV_u7XIE

Anotación: Guía de referencia técnica utilizada para estructurar la interfaz interactiva reactiva del software, la segregación de pestañas de navegación y la inyección de estilos de color.

Derivando. (2021). *La Ley de los Grandes Números: ¿Por qué los casinos siempre ganan?* [Video de YouTube]. Disponible en: https://www.youtube.com/watch?v=M8H_mGZ_30Q

Anotación: Material audiovisual analizado para estructurar la justificación teórica y el despliegue del gráfico iterativo de convergencia de la media muestral hacia la esperanza teórica.

Pelado Nerd. (2022). *Docker Containers desde Cero: Cómo encapsular tus aplicaciones de Python* [Video de YouTube]. Disponible en: https://www.youtube.com/watch?v=cvmSHe_vTlo

Anotación: Fuente consultada para el diseño y configuración del archivo `Dockerfile`, la exposición del puerto 8501 y el montaje dinámico de volúmenes locales dentro del contenedor.

9. Anexo: Repositorio e Instrucciones Adicionales

El código fuente completo, los archivos de configuración y los reportes están versionados bajo control de cambios en la siguiente dirección electrónica del repositorio remoto:

<https://github.com/Ruperto52/SimuladorDistribucionesProbabilidad/>

Para clonar y poner en marcha el sistema de manera interactiva mapeando los volúmenes de desarrollo en tiempo real desde la consola de comandos de Ubuntu, ejecute la siguiente secuencia:

```
git clone https://github.com/Ruperto52/SimuladorDistribucionesProbabilidad.git
cd SimuladorDistribucionesProbabilidad
sudo docker run -p 8501:8501 -v $(pwd):/app simulador-estadistica
```